

高等运筹学

期末专题

管理科学与工程学系

仲维礼

题目

星巴克 新门市位置

问题描述:星巴克企业想要在北京开设新的实体门店，根据它们的市场调查，发现只要有图书馆地方，人们就会有买咖啡的消费行为，因此在开设有限数量的门市下，希望这些店离图书馆距离不远。

模型建立与假设:这是经典的选址问题，我们采用 P-中位方法建构以下数学式，

$$\begin{aligned} \arg \min_s \sum_{i=1}^K \sum_{X \in S_i} \|X - \mu_i\|^2, i = 1, 2, \dots, K \\ \text{s.t. } \mu_1 + \mu_2 + \dots + \mu_K = n \\ \mu_i \text{ are bounded in } X \end{aligned}$$

Assumption: Each library is linked exactly one coffeeshop

Each coffeeshop can link not only one library

Coffeeshop cadidate locations are same as library location

数据集:透过百度地图开放资源我们可以获得全北京市图书馆的据点，但观察数据集后我们集中在北京的海淀区、东城区、西城区、朝阳区这四个区域，因为这四个区域的加总占全部数据集的十分之七，并且可以降低 outlier 点的影响。

原数据(400 笔)

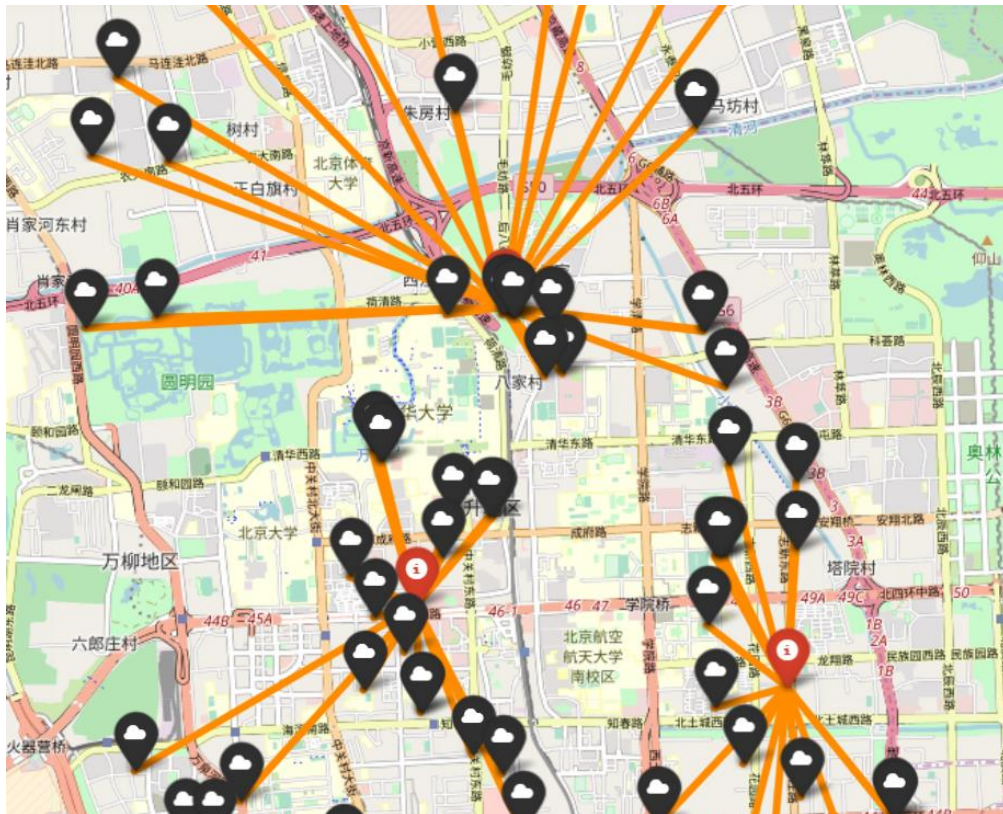
海淀区(95 笔)

	area	name	lat	lng		area	name	lat	lng
0	海淀区	中国国家图书馆	39.949641	116.330065	0	海淀区	中国国家图书馆	39.949641	116.330065
1	朝阳区	首都图书馆	39.875885	116.469182	1	海淀区	海淀区图书馆	39.984178	116.315950
2	西城区	北京图书大厦	39.914075	116.383456	2	海淀区	中国科学院文献情报中心	39.993046	116.329603
3	通州区	通州区图书馆	39.918552	116.693865	3	海淀区	清华大学法律图书馆楼	40.005203	116.335359
4	海淀区	海淀区图书馆	39.984178	116.315950	4	海淀区	北京大学-图书馆	39.997899	116.316801


求解方法:我们采用两种方法进行求解，一个是透过 cplex 另一个是透过机器学习中 K 均值聚类，cplex 由于软件建模方式，从原本线性规划问题变为混合整数规划， $\mu_i$  是经纬度不是整数的，而过程会利用二元矩阵代表这图书馆附近是有开还是没开，但由于此矩阵规模太大了，运算上无法负荷，因此我们采取分区运算有海淀区、东西城区、朝阳区分三部分求解。

求解结果 cplex:

海淀区(红色为新设咖啡门市据点；黑色为图书馆； $n=5$ )

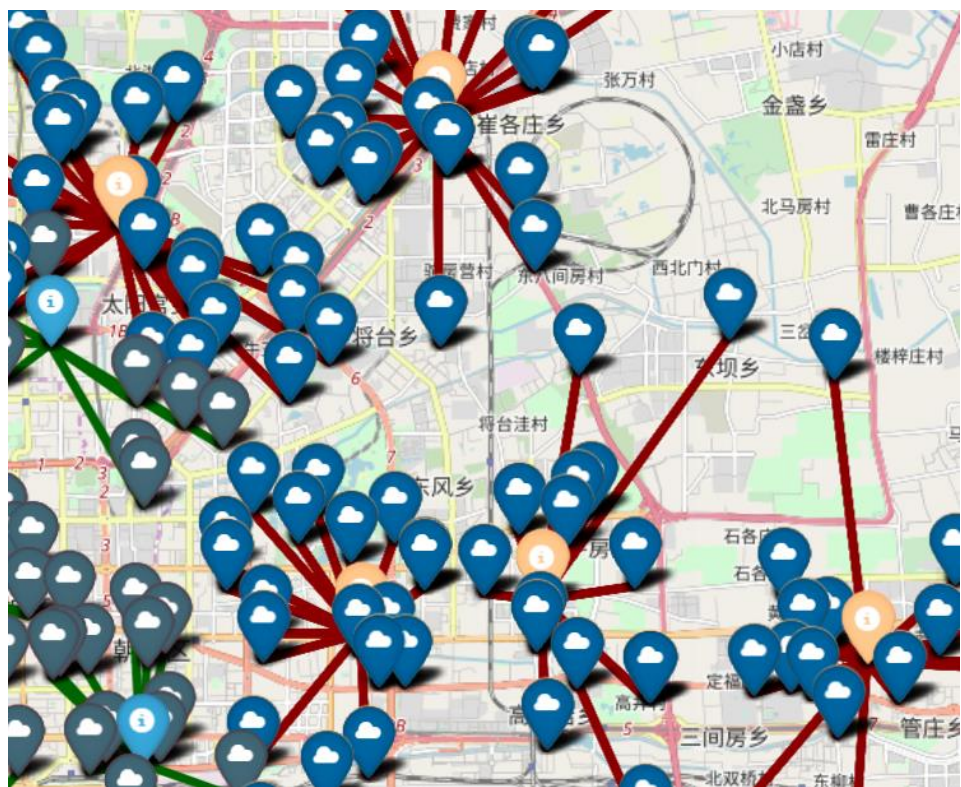


东西城区(浅蓝色为新设咖啡门市据点；深蓝色为图书馆； $n=5$ )







朝阳城区(橘色为新设咖啡门市据点；蓝色为图书馆；n=7)



总图



cplex、k-means 分区、k-means 不分区 新设咖啡门市据点结果比较:



cplex [红色]  
kmeans 分区 [蓝色]  
kmeans 不分区 [绿色]




cplex [红色]  
kmeans 分区 [蓝色]  
kmeans 不分区 [绿色]


可以发现 cplex 求解结果(红色)和 kmeans 分区(蓝色)几乎重迭，不完全重迭的原因是 cplex 的假设，其中一条，门市位置和图书馆位置相同，而 kmeans 并没有这条约束，至于 kmeans 不分区(绿色)结果与另两者不同是因为它没有分区的约束，所以相差更多。(详见附注距离计算)

cplex 求解结果与真实星巴克据点比较:


海淀区(红色为实际星巴克据点；蓝色为 cplex 求解结果；n=5)



东西城区(黑色为实际星巴克据点；蓝色为 cplex 求解结果；n=5)



朝阳区(黄色为实际星巴克据点；蓝色为 cplex 求解结果；n=7)



可以发现几件事情，我们预设的开店数目远远小于实际开的，毕竟星巴克要抢占市场不可能只开几间店，以及星巴克密度越高的地方，都有一个求解的结果或者星巴克据点的中心也有求解的结果，代表如果真的只能限制几家的话，或许求解结果真是不错的选择，当然星巴克企业每开一间门市是会考虑很多的，不可能仅仅只因为距离图书馆去设计，说不定其实是因为商圈去设计的，这些都可以去探讨的。

cplex 求解算法与代码实践:

我们的目标是要距离最小，所以肯定要设计距离函数:

---

```
def get_distance(pl, p2):  
    return great_circle((pl.x, pl.y), (p2.x, p2.y)).miles
```

约束一 (  $\mu_i$  are bounded in  $X$ ):

---

```
BIGNUM = 999999999  
for c_loc in coffeeshop_locations:  
    for b in libraries:  
        if get_distance(c_loc, b) >= BIGNUM:  
            mdl.add_constraint(link_vars[c_loc, b] == 0, "ct_forbid_  
                {0!s}_{1!s}".format(c_loc, b))
```

约束二 ( Each library is linked exactly one coffeeshop ):

---

```
mdl.add_constraints(mdl.sum(link_vars[c_loc, b] for c_loc in  
coffeeshop_locations) == 1  
                    for b in libraries)
```

约束三 ( Each coffeeshop can link not only one library ):

---

```
mdl.add_constraints(link_vars[c_loc, b] <= coffeeshop_vars[c_loc]  
                    for b in libraries  
                    for c_loc in coffeeshop_locations)
```

约束四 (  $\mu_1 + \mu_2 + \dots + \mu_K = n$  ):

---

```
mdl.add_constraint(mdl.sum(coffeeshop_vars[c_loc] for c_loc in  
coffeeshop_locations) == 5)
```

约束五 ( Coffeeshop cadidate locations are same as library location ):

---

```
libraries = set(libraries)  
coffeeshop_locations = libraries
```

求解

---

```
total_distance = mdl.sum(link_vars[c_loc, b] * get_distance(c_loc, b)  
for c_loc in coffeeshop_locations for b in libraries)  
mdl.minimize(total_distance)
```

## 二元矩阵(撷取片段)

Minimize:

obj:

Subject To:

c1:  $x_{75} - x_1 \leq 0$

c2:  $x_{149} - x_2 \leq 0$

c5489:  $x_{87} + x_{161} + x_{235} + x_{309} + x_{383} + x_{457} + x_{531} + x_{605} + x_{679} + x_{753} + x_{827} + x_{901} + x_{975} + x_{1049} + x_{1123} + x_{1197} + x_{1271} + x_{1345} + x_{1419} + x_{1493} + x_{1567} + x_{1641} + x_{1715} + x_{1789} + x_{1863} + x_{1937} + x_{2011} + x_{2085} + x_{2159} + x_{2233} + x_{2307} + x_{2381} + x_{2455} + x_{2529} + x_{2603} + x_{2677} + x_{2751} + x_{2825} + x_{2899} + x_{2973} + x_{3047} + x_{3121} + x_{3195} + x_{3269} + x_{3343} + x_{3417} + x_{3491} + x_{3565} + x_{3639} + x_{3713} + x_{3787} + x_{3861} + x_{3935} + x_{4009} + x_{4083} + x_{4157} + x_{4231} + x_{4305} + x_{4379} + x_{4453} + x_{4527} + x_{4601} + x_{4675} + x_{4749} + x_{4823} + x_{4897} + x_{4971} + x_{5045} + x_{5119} + x_{5193} + x_{5267} + x_{5341} + x_{5415} + x_{5489} = 1$

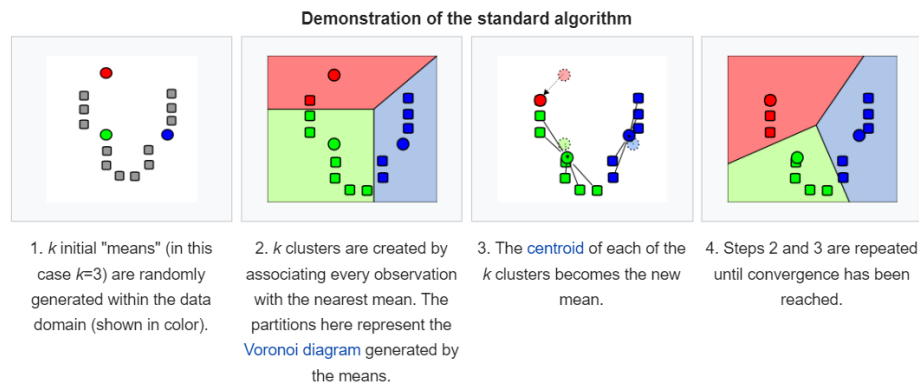
$0 \leq x_{35} \leq 1$

$0 \leq x_{36} \leq 1$

Binaries

$x_1 \ x_2 \ x_3 \ x_4 \ x_5 \ x_6 \ x_7 \dots\dots\dots$

kmeans 求解算法与代码实践:



```
kmeans=KMeans(n_clusters=5, random_state=0)
```

```
kmeans.fit(data_train)
```

附注距离计算

```
distances1 = np.linalg.norm(cplexAns - kmeans_sperate, axis=0)
```

```
distances2 = np.linalg.norm(cplexAns - kmeans_nosperate, axis=0)
```

```
distances1 = 0.3389108896235739
```

```
distances2 = 0.6523480768210991
```